



T.C.

DÜZCE ÜNİVERSİTESİ

YÖNETİM BİLİŞİM SİSTEMLERİ BÖLÜMÜ

MAKİNE ÖĞRENMESİ DERSİ

DÖNEM SONU ÖDEVİ

**MAKİNE ÖĞRENMESİ PROJESİ: AIRBNB YENİ KULLANICI
REZERVASYON TAHMİNİ**

AD SOYAD: Berkay YILMAZ

ÖĞRENCİ NO: 242211075

DERS HOCASI

Dr. Öğr. Fatma Betül KARA ARDAÇ

1.Giriş (Introduction)

Bu projede , Airbnb platformuna yeni dahil olan kullanıcıların demografik verilerini ve sistemsal bilgilerini analiz ederek ilk rezervasyonlarını hangi ülkeye yapacaklarını öngören bir model geliştirmeyi hedefledim. Günümüzde dijital platformlar için kullanıcı davranışlarını önceden kestirebilmek doğru pazarlama stratejisi kurmanın temel taşlarını oluşturuyor. Çalışmam da ham veriyi işleyerek anlamlı hale getirdikten sonra üç farklı makine algoritması eğittim bunlar ;(Logistic Regression , Random Forest Classifier, Gradient Boosting Classifier) ve performanslarını karşılaştırmalı olarak sundum.


2.Verİ Setİ (Dataset)

Çalışmamda “Airbnb New User Bookings” veri seti kullanılmıştır.

Hedef Değişken: Modelimizin tahmin etmeye çalıştığı hedef değişkenimiz “country_destination” sütunudur. Bu sütun, kullanıcıların seyahat ettiği ülkeleri ve rezervasyon yapmayan kullanıcıları temsil eden “NDF” sınıflarını içermektedir. Toplam 12 farklı sınıf bulunmaktadır.

Veri Analizi ve Dengesizlik: Veri seti üzerinde yapılan ön incelemelerde sınıf dağılımının oldukça dengesiz olduğu, kullanıcıların çok büyük bir kısmının “NDF” ve “US” sınıflarında yoğunlukta olduğu gözlenmiştir.

Aykırı Değerler: “Age” değişkeninde 2000,2014 gibi doğum yıllarının yaş olarak girildiği mantıksız aykırı değerler tespit edildi.



Şekil 1: Yaş değişkenindeki outlier değerlerin boxplot ile gösterimi

3.Metodoloji (Methodology)

3.1 Veri Ön İşleme (Data Preprocessing)

Modellerimizin daha sağlıklı bir şekilde eğitilebilmesi için öncelikle veriyi yanlış potansiyeli olan tarihler sütunlar ve id sütunu veri setinden çıkarılmıştı. Eksik veriler bulunan “age” sütunu medyan ile “first_affiliate_tracked” sütunu mod değerleri ile doldurulmuştur. Şekil 1’de tespit edilen mantıksız yaş değerleri sınıflandırılarak medyan değerine eşitlenmiştir. Kategorik yapıdaki tüm metin formatındaki veriler makine öğrenmesi algoritmalarının işleyebilmesi için Label Encoding yöntemiyle sayısallaştırılmış olup ardından verideki özelliklerin aynı ölçeğe getirilmesi amacıyla StandartScaler uygulanmıştır.

3.2. Kullanılacak Algoritmalar

Seçilen veri setine ve sınıflandırma modeline uygun olan 3 algoritma kullanılmıştır:

- Logistic Regression : Doğrusal ilişkileri modellemek için temel algoritma olarak seçilmiştir.
- Random Forest Classifier : Aşırı öğrenmeyi (Overfitting) engelleyen ve karmaşık veri yapılarında yüksek başarı elde eden ağaç tabanlı topluluk modelidir.
- Gradient Boosting Classifier : Zayıf tahmin edicileri ardışık olarak eğiterek hataları minimize etmeyi hedefleyen güçlü bir algoritmadır.

3.3. Deneysel Tasarım ve Optimizasyon


Veri seti, sınıfların dengeli dağılmasını sağlamak amacıyla stratify parametresi kullanılarak %80 eğitim %20 test olarak ikiye ayrılmıştır. Tüm modeller önce varsayılan parametreleri ile aynı veri seti üzerinden eğitilmiştir. Ardından modellerin performansını maksimize etmek amacıyla RandomizedSearchCV kullanılarak hiperparametre optimizasyonu yapılmıştır. Ve aynı zamanda n_iter=50 parametresi ile geniş çaplı bir hiperparametre uzayı taranmış ve modellerin en iyi konfigürasyonları tespit edilmiştir.

4.Sonuçlar (Results)


Sınıflandırma algoritmalarının test seti üzerindeki performansları Accuracy , Precision , Recall ve F1-Score metrikleri ile hesaplanmıştır.

	Accuracy	Precision	Recall	F1-score
Logistic Regression	0.590171	0.482683	0.590171	0.500165
Random Forest	0.628282	0.536317	0.628282	0.574105
Gradient Boosting	0.629126	0.539545	0.629126	0.577799

Tablo 1: Optimize Edilmiş Modellerin Performans Metrikleri Karşılaştırılması



Şekil 2: Model Performanslarının Bar Grafiği ile Karşılaştırılması



Şekil 3,4,5: 3 Algoritmaya Ait Karmaşıklık Matrisleri

5.Tartışma (Discussion)

Elde edilen sonuçlar incelendiğinde ağaç tabanlı algoritmalar olan Gradient Boosting ve Random Forest’ in Logistic Regression modeline kıyasla daha yüksek Accuracy skoruna yaklaşık %63 değerine ulaştığı görülmüştür. Doğrusal modellerin bu veri setinde nispeten düşük kalmasının sebebi kullanıcı davranışları ile destinasyon seçimi arasındaki ilişkilerin karmaşık ve doğrusal olmayan bir yapıda olmasıdır.

Şekil 3,4,5 ‘teki Karşıklık Matrisleri incelendiğinde modellerin “NDF” ve “US” sınıflarını çok yüksek isabetle doğru tahmin ettiği görülmektedir. Ancak diğer azınlık sınıflarda modelin tahmin zorluğu yaşadığı ve bu sınıfları birbiriyle veya “US” sınıfıyla karıştırdığı tespit edilmiştir. Bu durum accuracy oranımızın yüksek çıkmasına rağmen precision ve recall metriklerinin NDF baskınlığı nedeniyle bir miktar baskılandığı kanıtlanmaktadır. 50 iterasyonluk kapsamlı hiperparametre optimizasyonu modelin ezberlemesini engelleyerek genelleme yeteneğini artırmıştır.

6.Sonuç (Conclusion)

Bu projede aynı veri seti kullanılarak 3 farklı makine öğrenmesi modeli eğitilmiş ve performansları başarıyla karşılaştırılmıştır. Elde edilen sonuçlara göre Gradient Boosting algoritmasının bu veri seti üzerinde diğer modellere kıyasla daha başarılı performans gösterdiği görülmüştür. Gelecek çalışmalarda hedef değişkendeki sınıf dengesizliğini çözmek için SMOTE gibi veri artırma yöntemlerinin kullanılması veya kullanıcıların site içi tıklama loglarını barındıran ek veri setlerinin modele entegre edilmesi ile tahmin başarısı daha da artacağı düşünülmektedir.